

Laptop Price EDA and Result Report

This dataset, which contains laptop pricing and feature information, was in a semi-structured form, and frankly, there was not much that could be done in an inferential sense. The results were of a nature that could be intuitively inferred. However, since this dataset contained various features such as brand, type, memory size, RAM, etc., recorded within a single variable, variables were created by extracting Laptop_ID, Discounted_Price, Actual_Price, Rating, Reviews, Brand, Core, SSD, Series, Processor, RAM, and Storage from the main dataset and applying feature engineering processes (SQL was used for these operations).

As a result of these processes, the analysis was transferred to the Python Jupyter Notebook environment for descriptive statistical analysis. Using the “describe” command, the mean, standard deviation, minimum and maximum values, and quartile distributions of numerical variables were examined in order to understand the data.

Among the numerical variables, Rating, Reviews, Discounted_Price, and Actual_Price were interpreted as having interquartile ranges and potentially containing outlier values. To extract more detailed meaning, visualizations were applied, and outliers and distribution normality were examined using box plots and bar charts.

It was observed that the Reviews and Rating results did not exhibit a meaningful distribution, were concentrated at specific values, and had a limited number of distinct observations. Discounted_Price and Actual_Price variables were found to be left-skewed, and their distributions deviated from normality due to a small number of outliers.

The categorical variables Brand, Core, SSD, Series, Processor, RAM, and Storage were examined in terms of data counts and distribution density. Certain specific values were clearly observed. Accordingly, HP and Lenovo brands constituted nearly half of the market, Intel processors established significant dominance in the market, 512GB SSDs were overwhelmingly preferred as storage (listed in fragmented form due to certain shortcomings during text processing), and 8GB and 16GB RAM preferences accounted for nearly the entire market.

Subsequently, prior to performing inferential statistics, distribution and scatter plots were examined to visually interpret the data distributions. Two distinct clusters were clearly observed in the Discounted_Price and Actual_Price variables. Accordingly, a clear inference regarding the correlation between them was visually observable, while outliers disrupting the distribution were also identified. In the same plots, clustering was clearly observed for the Rating and Reviews variables, and it was determined that meaningful results could not be produced from them.

To test whether categorical variables had an effect on one another, a chi-square test was conducted, and independence was identified between Brand and the RAM, SSD, and Storage variables. This indicates that while Brand operates independently of RAM, SSD, and Storage hardware, it uses its own predefined hardware configurations for other variables.

The normality of numerical variables was tested using the Kolmogorov–Smirnov test, and the lack of normality was numerically proven. Additionally, a homogeneity test was conducted to measure the relationship with categorical variables, and homogeneity was identified.

Due to the non-normal distribution, a non-parametric approach was preferred. This is because no logical argument could be observed to justify removing outliers from the dataset. According to the non-parametric correlation test (Spearman), a strong correlation was identified between Actual_Price and Discounted_Price, while the effects of Reviews and Rating variables were observed to be weak.

To test the effects between categorical and numerical variables, the robust PERMANOVA test was applied to examine the relationship between all numerical and categorical variables. According to the results, significant differences were identified except for the Brand, RAM, and SSD variables. The results indicate that the Brand, RAM, and SSD variables create significant differences for the Actual_Price and Discounted_Price variables. In other words, some groups within these three categorical variables exhibit significantly different pricing and discounting.

As a result of all these descriptive and inferential statistical tests, the data was understood, and the analysis proceeded to inferential and decision-making statistical tests.

Inferential Statistics

As a result of the tests conducted in the first section, the Reviews and Rating variables were excluded from inferential statistics due to their lack of meaningful results. A hypothesis test for paired observations was conducted to observe whether there was a significant difference between Actual_Price and Discounted_Price, and no meaningful relationship was found between them.

Subsequently, regression analysis was performed; however, due to the sensitivity of regression tests to extreme values, null and outlier values were removed from the dataset, and the relationship between Actual_Price and Discounted_Price was tested. According to the results, it was determined that Actual_Price explains the Discounted_Price variable at a very high rate of 0.956. This indicates that discounts are applied within the context of pricing.

To understand what affects the Actual_Price variable, a multiple regression analysis was conducted between Actual_Price and the available categorical variables. It was determined that hardware features have an effect on pricing for all brands except Apple and Lenovo.

It is considered that due to Apple's global brand recognition and the demand created by Lenovo's market dominance in the domestic market, pricing is influenced by factors beyond hardware specifications for these brands.

Conclusion

Overall, it was determined that customer preferences tend toward higher memory, RAM, and SSD specifications. In contrast, for features such as brand and processor, whose significance cannot be intuitively quantified, a customer profile driven by concentration and brand recognition was identified (likewise, in addition to Intel's brand recognition, higher-tier models such as 7, 5, and Pro are observed to be more frequently preferred). Nevertheless, due to their impact on pricing, hardware features that indicate numerical or qualitative superiority are preferred at values closest to the top, even if they are not the absolute highest.

Accordingly, it is recommended that the sales strategy be structured to increase profit margins on well-known products and to apply higher discount rates to those products in order to increase profitability. Additionally, it is suggested that for hardware components known to be at the highest level, the price impact of near-top (but not absolute top-tier) specifications be increased to boost the sales rate of top-tier configurations, thereby enhancing the perception of “quality.”

Türkçe:

Dizüstü bilgisayar fiyatlandırma ve özelliklerinin yer aldığı bu veri seti, yarı yapılandırılmış bir haldeydi ve açıkçası çıkarımsal anlamda çok fazla yapılacak bir hamle yoktu. Sonuçlar, sezgisel olarak çıkarılabilecek bir nitelikteydi. Ancak marka, tür, hafıza büyüklüğü, RAM... gibi çeşitli özelliklerin tek bir değişkende kaydının tutulduğu bu veri seti; Laptop_ID, Discounted_Price, Actual_Price, Rating, Reviews, Brand, Core, SSD, Series, Processor, RAM, Storage değişkenleri ana veri setinden alınarak ve feature engineering işlemleri yapılarak değişkenler oluşturuldu (bu işlemler için SQL kullanıldı).

İşlemler sonucu verilerin tanımlayıcı istatistik işlemleri için Python Jupyter Notebook ortamına geçildi. “describe” komutuyla sayısal verilerin ortalama, standart sapma, min ve max değerler ve çeyreklik dağılımlarına bakılarak veri anlaşılmasına çalışıldı.

Sayısal veriler olarak Rating, Reviews, Discounted_Price ve Actual_Price değerlerinin genel olarak çeyreklik açıklığı bulunduğu ve outlier değerlere sahip olabileceği düşünüldü ve yorumlandı. Daha detaylı anlam çıkarabilmek adına görselleştirme uygulanarak box plot ve sütun grafiğiyle aykırı değerler ve dağılımın normalliği kontrol edildi.

Verilerde Reviews ve Rating sonuçlarının anlamlı bir dağılım göstermediği ve spesifik bir değerde yoğunlaştığı ve harici belli başlı değerler olduğu anlaşıldı. Discounted_Price ve Actual_Price değişkenlerininse sola çarpık olduğu ve dağılımın normallikten birkaç aykırı değerle saptığı tespit edildi.

Brand, Core, SSD, Series, Processor, RAM, Storage kategorik değişkenlerinin veri adedine ve dağılım yoğunluğuna bakıldı. Spesifik birtakım değerler net şekilde gözlemlendi. Buna göre HP ve Lenovo markalar piyasanın yarısını oluşturuyor, Intel işlemciler piyasada ciddi bir dominasyon kuruyor, SSD olarak 512gb SSD'ler çok baskın bir biçimde tercih ediliyor (metin işlemeciliği esnasında yapılan birtakım eksikliklerden dolayı parçalı şekilde listeleniyor), RAM olarak 8 ve 16gb RAM tercihi neredeyse piyasanın tamamını oluşturuyor.

Daha sonrasında çıkarımsal istatistik yapmadan önce verilerin dağılımını görsel olarak anlamlandırmak adına dağılım ve saçılım grafiklerine bakıldığında Discounted_Price ve Actual_Price değişkenlerinde net iki grup gözlemleniyor. Buna göre aralarındaki korelasyon hakkında da net bir çıkarsama görselde gözlemlenmekle birlikte dağılımı bozan aykırı değerler de tespit ediliyor. Yine aynı grafiklerde Rating ve Reviews değişkenlerinde yumulma net şekilde gözlemleniyor ve anlamlı bir sonuç üretilmeyeceği tespit ediliyor.

Kategorik değişkenlerin birbirine etkisi olup olmadığı test edilmek adına kikare testi yapılıyor ve Brand ile RAM, SSD ve Storage değişkenleriyle bir bağımsızlık tespit ediliyor. Bu da göstermektedir ki Brand; RAM, SSD ve Storage donanımları için markadan bağımsız hareket ederken diğer değişkenler için kendi hazır donanım özelliklerini kullanıyor.

Sayısal değişkenlerin normalliği Kolmogorov Smirnov ile test edilerek normalliğin sağlanmadığı sayısal olarak ispatlanıyor. Ayrıca kategorik değişkenlerle olan ilişkiyi ölçeklemek için homojenlik testi de yapılıyor ve homojenlik tespit ediliyor.

Dağılımın normal dağılım göstermemesinden ötürü non-parametrik yaklaşım tercih ediliyor. Çünkü aykırı değerlerin veri setinden çıkartılabilmesi için mantıksal bir argüman

gözlemlenemiyor. Yapılan non-parametrik korelasyon testine göre (Spearman) Actual_Price ile Discounted_Price'nin güçlü bir korelasyonu tespit edilirken Reviews ve Rating değişkenlerinin etkilerinin zayıf kaldığı gözlemleniyor.

Kategorik değişkenlerle sayısal değişkenlerin etkisini test etmek adına robuts özellik gösteren PERMANOVA testiyle tüm sayısal değişkenler ve kategorik değişkenler arasındaki ilişki test ediliyor ve sonuçlara göre Brand, RAM ve SSD değişkenleri haricinde anlamlı farklılık tespit ediliyor. Sonuçlara göre Brand, RAM ve SSD değişkenleri; Actual_Price ve Discounted_Price değişkenleri için anlamlı farklılık oluşturuyor. Yani bu üç kategorik değişkenin içindeki bazı grupların fiyatlandırması ve indirimi anlamlı bir biçimde farklılık gösteriyor.

Yapılan tüm bu tanımsal ve çıkarımsal istatistik testleri sonucunda veri tanınıyor ve çıkarımsal ve karar verici istatistik testlerine geçiliyor.

Çıkarımsal İstatistik:

İlk bölümde yapılan testler sonucunda Reviews ve Rating değişkenlerinin anlamlı sonuçlar vermediği için çıkarımsal istatistiğin dışında bırakılıyor ve Actual_Price ile Discounted_Price değişkenleri arasında anlamlı bir farklılık olup olmadığını gözlemlemek için eşleştirilmiş gözlemler için hipotez testi yapılıyor ve ikisi arasında anlamlı bir bağıntı bulunamıyor.

Sonrasında regresyon testine geçiliyor ancak regresyon testinin uç değerlere karşı duyarlılığından ötürü null ve uç değerler veri setinden çıkarılarak Actual_Price ile Discounted_Price arasındaki ilişki test ediliyor. Sonuçlara göre Actual_Price 0,956 gibi oldukça yüksek bir oranda Discounted_Price değişkenini açıkladığı tespit ediliyor. Yani indirimler, fiyatlandırma bağlamında yapılıyor.

Actual_Price değişkenini neyin etkilediği anlaşılması için eldeki kategorik değişkenlerle Actual_Price arasında da bir çoklu regresyon testi yapılıyor ve Apple ve Lenovo markaları harici tüm markalar için donanım özelliklerinin fiyatlandırmada etkisi tespit ediliyor.

Apple'ın global çapta bilinirliği ve Lenovo'nun ülke içi piyasada kurduğu dominasyon sonucu oluşturduğu talepten ötürü donanım özellikleri harici fiyatlandırmasında etki ettiği düşünülüyor.

Sonuç:

Genel olarak müşteri eğiliminin yüksek hafıza, RAM, SSD özelliklerine yöneldiği ve bunun yanı sıra anlamlılığı sezgisel olarak bilinmeyen marka, işlemci gibi özelliklerdeyse yoğunlaşma ve bilinirlik üzerinden hareket eden bir müşteri profili olduğu tespit edilmiştir (keza Intel'in bilinirliğinin yanı sıra 7, 5, pro gibi daha üst düzeylik belirten modellerin daha çok tercih edildiği de tespit edilmektedir). Ancak buna rağmen fiyatlandırmaya olan tesirinden dolayı sayısal ya da niteliksel olarak üstünlük belirten donanımsal özelliklerde en zirve olmasa da zirveye en yakın değerler tercih edilmektedir.

Buna göre satış politikası, bilindik ürünlerde kar marjını artırma ve indirim oranını o ürünlerde daha çok artırma üzerine kurularak karlılığın artırılması önerilmekte ve donanımsal özellik olarak en üst seviye olduğu bilinen donanımlarda zirve olmayan özelliklerin fiyata tesiri artırılarak en üst özelliğin satış oranı artırılarak "kalite" algısının yükseltilmesi hedeflenmesi önerilir.